

BÁO CÁO KẾT QUẢ BÀI TẬP

Phân loại người sống sót trên tàu Titanic

Giảng viên hướng dẫn: TS. Đỗ Như Tài

Sinh viên thực hiện:

Trần Đình Hải
Huỳnh Nhật Minh
Lê Thành Nhân
Trần Công Minh

Trường Đại học Sài Gòn

Ngày 26 tháng 10 năm 2025

Presentation Overview


- 1 Định nghĩa vấn đề
- 2 Phân tích dữ liệu khám phá - EDA
- 3 Chuẩn bị dữ liệu và xử lý đặc trưng

Định nghĩa vấn đề

- Mục tiêu: Dự đoán hành khách **sống sót hay không** trên tàu Titanic.
- **train.csv**: chứa đặc điểm hành khách và nhãn Survived (0 = Không, 1 = Có).
- **test.csv**: chứa các đặc điểm tương tự, **không có cột Survived**.
- Dữ liệu dùng để huấn luyện và kiểm tra mô hình học máy.

Đặc trưng đầu vào và đầu ra

- **Pclass:** Hạng vé (1–3)
- **Name:** Tên hành khách
- **Sex:** Giới tính (nam/nữ)
- **Age:** Tuổi (năm)
- **SibSp:** Số anh chị em / vợ chồng đi cùng
- **Parch:** Số cha mẹ / con cái đi cùng
- **Ticket:** Số vé
- **Fare:** Giá vé (bảng Anh)
- **Cabin:** Mã phòng hoặc khoang tàu
- **Embarked:** Cảng lên tàu (C/Q/S)



Tổng quan và tính toàn vẹn dữ liệu

- Tập **train.csv**: 891 dòng, 12 cột
- Biến gồm dạng số và dạng chuỗi
- Thiếu dữ liệu ở: Age, Cabin, Embarked
- **Age**: 177 thiếu (20%), **Cabin**: 687 thiếu (77%), **Embarked**: 2 thiếu (<1%)
- Cột mục tiêu: **Survived** (0 = Không, 1 = Có)
- Không có bản ghi trùng → Dữ liệu duy nhất (unique)


Thống kê mô tả và Phân bố biến phân lớp (Survived)

Thống kê mô tả các biến số:


- **Pclass:** Trung bình 2.31 $\rightarrow$ đa số hạng 2–3
- **Age:** TB $\approx$ 29.7, lệch chuẩn $\approx$ 14.5 (0.42–80)
- **SibSp/Parch:** Đa số đi một mình, tối đa 8 anh chị em hoặc 6 cha mẹ/con
- **Fare:** TB $\approx$ 32.2, lệch chuẩn $\approx$ 49.7, có outlier đến 512.33

Phân bố biến phân lớp Survived:

- Dữ liệu hơi **mất cân bằng (imbalanced)**.



Đơn biến (Univariate Plots)





Hình: biểu đồ minh họa phân bố Survived

- Số lượng hành khách **không sống sót (549)** cao hơn đáng kể so với **sống sót (342)**.
- Phần lớn hành khách đã không qua khỏi, chiếm khoảng **61.6%** tổng

Box and Whisker Plots

- **Age:** 20–38 tuổi, trung vị 28–30, có outliers lớn tuổi.
- **SibSp:** 75% từ 0–1, trung vị 0, vài giá trị ngoại lệ.
- **Parch:** Đa số 0, có outliers.
- **Fare:** Lệch phải mạnh, trung vị < 20, outliers > 500.
- **Fare** có thang đo lớn → các biến khác bị nén ở đáy.




Histogram (Sex vs Survived)

- **Giới tính là yếu tố dự đoán mạnh nhất.**
- **Nữ (female):**
 - Tỷ lệ sống sót vượt trội.
 - Số sống sót cao hơn tử vong.
 - 233/342 người sống sót là nữ (68%).
- **Nam (male):**
 - Tỷ lệ tử vong rất cao.
 - 468/549 người tử vong là nam (85%).



Phân tích theo hạng vé (Pclass)

- Hạng vé càng cao → cơ hội sống càng lớn.
- Hạng 1: sống sót nhiều hơn tử vong.
- Hạng 2: gần cân bằng.
- Hạng 3: tử vong áp đảo.
- Pclass thể hiện rõ ảnh hưởng của địa vị xã hội.




Phân tích đa biến (Multivariate Analysis)

- Hạng vé cao $\Rightarrow$ cơ hội sống cao hơn.
- Người sống sót thường trẻ và trả vé cao hơn.
- Gia đình nhỏ (1–2 người đi cùng) có tỉ lệ sống tốt hơn.
- **Fare** và **Pclass** tương quan nghịch rõ rệt.
- **Age**, **SibSp**, **Parch** ít tương quan mạnh.



Ma trận tương quan


- Không biến nào $|r| > 0.8$
- Pclass-Fare: tương quan mạnh
- SibSp-Parch: liên hệ nhẹ
- Age: gần như độc lập



Phân bố sống sót

- Age: Trẻ có lợi thế sống sót
- Fare: Vé cao hạng sang sống sót nhiều
- Pclass: Hạng 1–2 sống sót, hạng 3 tử vong đa số
- SibSp/Parch: có 1–2 người đi cùng sống cao hơn

Boxplot grouped by Survived



Tạo đặc trưng mới (Feature Engineering)

(1) $\text{FamilySize} = \text{SibSp} + \text{Parch} + 1$

- Người đi một mình sống sót rất ít.
- Gia đình nhỏ (2–4 người) có tỉ lệ sống cao nhất.
- Gia đình lớn (>5) khó sống sót do khó hỗ trợ nhau.

(2) Title (Mr, Mrs, Miss, Master, Other)

- **Mr:** đông nhất, tỉ lệ tử vong cao.
- **Mrs, Miss, Master:** sống sót nhiều hơn rõ rệt.
- **Other:** hiếm, đa phần tử vong.

Xử lý giá trị thiếu và Mã hoá dữ liệu

- **Age:** điền bằng giá trị trung bình.
- **Embarked:** thay bằng giá trị xuất hiện nhiều nhất.
- **Cabin:** xoá do thiếu quá nhiều.
- **Mã hoá danh mục:** dùng LabelEncoder cho *Sex*, *Embarked*, *Title*, *Family_cate*.
- Sau mã hoá: *Sex* $\rightarrow$ [*female*, *male*], *Embarked* $\rightarrow$ [*C*, *Q*, *S*], *Title* $\rightarrow$ [*Master*, *Miss*, *Mr*, *Mrs*, *Other*], *Family_cate* $\rightarrow$ [*Alone*, *Small*, *Medium*, *Large*].

Chuẩn hóa dữ liệu

Biến	Phạm vi gốc	Chuẩn hóa
Age	0.42 - 80	[0,1]
Fare	0 - 512	[0,1]
Parch	0 - 6	[0,1]
SibSp	0 - 8	[0,1]
FamilySize	1 - 11	[0,1]

Scale, min, max được tính tự động

Cảm ơn thầy và các bạn!