

BÁO CÁO KẾT QUẢ BÀI TẬP

Phân loại người sống sót trên tàu Titanic

Giảng viên hướng dẫn: TS. Đỗ Như Tài

Sinh viên thực hiện:

Trần Đình Hải
Huỳnh Nhật Minh
Lê Thành Nhân
Trần Công Minh

Trường Đại học Sài Gòn

Ngày 2 tháng 11 năm 2025

Presentation Overview


- 1 Định nghĩa vấn đề
- 2 Phân tích dữ liệu khám phá - EDA
- 3 Chuẩn bị dữ liệu và xử lý đặc trưng
- 4 Huấn luyện mô hình

Định nghĩa vấn đề

- Mục tiêu: Dự đoán hành khách **sống sót hay không** trên tàu Titanic.
- **train.csv**: chứa đặc điểm hành khách và nhãn Survived (0 = Không, 1 = Có).
- **test.csv**: chứa các đặc điểm tương tự, **không có cột Survived**.
- Dữ liệu dùng để huấn luyện và kiểm tra mô hình học máy.

Đặc trưng đầu vào và đầu ra

- **Pclass**: Hạng vé (1–3)
- **Name**: Tên hành khách
- **Sex**: Giới tính (nam/nữ)
- **Age**: Tuổi (năm)
- **SibSp**: Số anh chị em / vợ chồng đi cùng
- **Parch**: Số cha mẹ / con cái đi cùng
- **Ticket**: Số vé
- **Fare**: Giá vé (bảng Anh)
- **Cabin**: Mã phòng hoặc khoang tàu
- **Embarked**: Cảng lên tàu (C/Q/S)



Tổng quan và tính toàn vẹn dữ liệu

- Tập **train.csv**: 891 dòng, 12 cột
- Biến gồm dạng số và dạng chuỗi
- Thiếu dữ liệu ở: Age, Cabin, Embarked
- **Age**: 177 thiếu (20%), **Cabin**: 687 thiếu (77%), **Embarked**: 2 thiếu (<1%)
- Cột mục tiêu: **Survived** (0 = Không, 1 = Có)
- Không có bản ghi trùng → Dữ liệu duy nhất (unique)


Thống kê mô tả và Phân bố biến phân lớp (Survived)

Thống kê mô tả các biến số:


- **Pclass:** Trung bình 2.31 $\rightarrow$ đa số hạng 2–3
- **Age:** TB $\approx$ 29.7, lệch chuẩn $\approx$ 14.5 (0.42–80)
- **SibSp/Parch:** Đa số đi một mình, tối đa 8 anh chị em hoặc 6 cha mẹ/con
- **Fare:** TB $\approx$ 32.2, lệch chuẩn $\approx$ 49.7, có outlier đến 512.33

Phân bố biến phân lớp Survived:

- Dữ liệu hơi **mất cân bằng (imbalanced)**.





Đơn biến (Univariate Plots)




- Số lượng hành khách **không sống sót (549)** cao hơn đáng kể so với **sống sót (342)**.
- Phần lớn hành khách đã không qua khỏi, chiếm khoảng **61.6%** tổng khách.

Box and Whisker Plots

- **Age:** 20–38 tuổi, trung vị 28–30, có outliers lớn tuổi.
- **SibSp:** 75% từ 0–1, trung vị 0, vài giá trị ngoại lệ.
- **Parch:** Đa số 0, có outliers.
- **Fare:** Lệch phải mạnh, trung vị < 20, outliers > 500.
- **Fare** có thang đo lớn → các biến khác bị nén ở đáy.




Phân bố tuổi theo tình trạng sống sót



- Trẻ em được ưu tiên rõ rệt
- Đỉnh sống sót cao ở nhóm <10
- Người lớn (20–40) tử vong nhiều
- Đây là nhóm tuổi đông nhất
- “Ưu tiên trẻ em” thể hiện rõ
- Nam 20–40 có rủi ro cao nhất


Histogram (Sex vs Survived)

- **Giới tính là yếu tố dự đoán mạnh nhất.**
- **Nữ (female):**
 - Tỷ lệ sống sót vượt trội.
 - Số sống sót cao hơn tử vong.
 - 233/342 người sống sót là nữ (68%).
- **Nam (male):**
 - Tỷ lệ tử vong rất cao.
 - 468/549 người tử vong là nam (85%).



Phân tích theo hạng vé (Pclass)

- Hạng vé càng cao → cơ hội sống càng lớn.
- Hạng 1: sống sót nhiều hơn tử vong.
- Hạng 2: gần cân bằng.
- Hạng 3: tử vong áp đảo.
- Pclass thể hiện rõ ảnh hưởng của địa vị xã hội.




Phân tích đa biến (Multivariate Analysis)

- Hạng vé cao $\Rightarrow$ cơ hội sống cao hơn.
- Người sống sót thường trẻ và trả vé cao hơn.
- Gia đình nhỏ (1–2 người đi cùng) có tỉ lệ sống tốt hơn.
- **Fare** và **Pclass** tương quan nghịch rõ rệt.
- **Age**, **SibSp**, **Parch** ít tương quan mạnh.



Ma trận tương quan


- Không biến nào $|r| > 0.8$
- Pclass-Fare: tương quan mạnh
- SibSp-Parch: liên hệ nhẹ
- Age: gần như độc lập



Phân bố sống sót

- Age: Trẻ có lợi thế sống sót
- Fare: Vé cao hạng sang sống sót nhiều
- Pclass: Hạng 1–2 sống sót, hạng 3 tử vong đa số
- SibSp/Parch: có 1–2 người đi cùng sống cao hơn

Boxplot grouped by Survived



Tạo đặc trưng mới (Feature Engineering)

(1) **FamilySize = SibSp + Parch + 1**

- Người đi một mình sống sót rất ít.
- Gia đình nhỏ (2–4 người) có tỉ lệ sống cao nhất.
- Gia đình lớn (>5) khó sống sót do khó hỗ trợ nhau.

(2) **Title (Mr, Mrs, Miss, Master, Other)**

- **Mr:** đông nhất, tỉ lệ tử vong cao.
- **Mrs, Miss, Master:** sống sót nhiều hơn rõ rệt.
- **Other:** hiếm, đa phần tử vong.

Xử lý giá trị thiếu và Mã hoá dữ liệu

- **Age:** điền bằng giá trị trung bình.
- **Embarked:** thay bằng giá trị xuất hiện nhiều nhất.
- **Cabin:** xoá do thiếu quá nhiều.
- **Mã hoá danh mục:** dùng LabelEncoder cho *Sex*, *Embarked*, *Title*, *Family_cate*.
- Sau mã hoá: *Sex* → [*female*, *male*], *Embarked* → [*C*, *Q*, *S*], *Title* → [*Master*, *Miss*, *Mr*, *Mrs*, *Other*], *Family_cate* → [*Alone*, *Small*, *Medium*, *Large*].

Chuẩn hóa dữ liệu

Phương pháp: Dữ liệu được chuẩn hóa bằng **StandardScaler** và **MinMaxScaler** để đưa các đặc trưng về cùng thang đo, tránh sai lệch do đơn vị khác nhau.

Biến	Phạm vi gốc	MinMaxScaler	StandardScaler
Age	0.42 – 80.00	[0, 1]	[-2.2, 2.5]
Fare	0.00 – 512.33	[0, 1]	[-0.6, 9.8]
Parch	0 – 6	[0, 1]	[-0.5, 6.0]
SibSp	0 – 8	[0, 1]	[-0.5, 7.0]
FamilySize	1 – 11	[0, 1]	[-0.5, 6.0]

Các giá trị min và max được tính tự động từ tập huấn luyện. **StandardScaler** đưa dữ liệu về trung bình 0 và độ lệch chuẩn 1, nhưng do tồn tại nhiều outlier (đặc biệt ở *Fare*), một số giá trị vượt quá khoảng [-3, 3].

Đánh Giá – StandardScaler


Dữ liệu: `df_standard.xlsx`

Chiến lược: K-Fold CV ($k = 5$,
Stratified) $\Rightarrow$ Metric: **Accuracy**
(Mean $\pm$ Std) **Kích thước:**

X_{train} : (891, 10 features)

y_{train} : (891,)

Mỗi fold: ~ 712 train, ~ 179 valid




Quy trình đánh giá với **StandardScaler**
chuẩn hóa theo z-score

Kết Quả Baseline – StandardScaler

Mô hình	Acc	Std	Rank
SVM	0.8238	± 0.0175	1
NB	0.8014	± 0.0213	2
KNN	0.8013	± 0.0171	3
LDA	0.8002	± 0.0327	4
LogReg	0.7890	± 0.0204	5
CART	0.7744	± 0.0188	6

- SVM cao nhất (0.8238), ổn định, overfit +2.84%
- NB, KNN $\approx 80.1\%$; LDA, LogReg ổn
- CART thấp nhất (0.7744), overfit +4.16%
- SVM vượt 1–5%

Phân Tích Boxplot – StandardScaler



- SVM: Hiệu suất cao, ổn định tốt
- KNN, LDA: Hiệu suất khá, ổn định
- NB: Ổn định, accuracy trung bình
- LR: Accuracy thấp hơn, ổn định
- CART: Thấp nhất, biến thiên cao

Tuning & Kết Quả Final – StandardScaler

Mô hình	CV Acc	Train Acc
LogReg	0.8070	0.8070
SVM	0.8283	0.8339

- LogReg: C=1.0, l1, balanced
- SVM: C=200, gamma=0.01
- SVM $\uparrow$ +0.45pp vs baseline
- Chênh Train-CV: +0.56% $\rightarrow$ ổn định
- **Chọn SVM, LR làm final**

Kết Quả Test – StandardScaler

Mô hình	Not Survived	Survived
LR	127	291
SVM	222	196

- **SVM** dự đoán cân bằng hơn.
- Giảm lệch lớp, ổn định hơn LR.
- **LR** thiên về lớp sống sót.
- Chốt: **SVM + StandardScaler** hiệu quả nhất.

Đánh Giá – MinMaxScaler


Dữ liệu: df_minmax.xlsx

Chiến lược: K-Fold CV ($k = 5$,
Stratified) $\Rightarrow$ Metric: **Accuracy**
(Mean $\pm$ Std) **Kích thước:**

X_{train} : (891, 10 features)

y_{train} : (891,)

Mỗi fold: ~ 712 train, ~ 179 valid




Quy trình đánh giá với **MinMaxScaler**
chuẩn hóa dữ liệu về khoảng $[0, 1]$

Kết Quả Baseline – MinMaxScaler

Mô hình	Acc	Std	Rank
SVM	0.8317	± 0.0117	1
LR	0.8047	± 0.0215	2
KNN	0.8036	± 0.0218	3
LDA	0.7991	± 0.0224	4
NB	0.7969	± 0.0080	5
CART	0.7755	± 0.0291	6

- SVM cao nhất (0.8317), ổn định nhất (± 0.0117)
- LR, KNN $\approx 80.4\%$; LDA, NB ổn
- CART thấp nhất (0.7755), biến động cao
- MinMax > Standard: SVM +0.79%, CART +0.14%

Boxplot Baseline – MinMaxScaler



- SVM: Median 0.8258, hộp hẹp, ổn định
- LR: Median 0.8034, ổn định tốt
- KNN, LDA: ≈ 0.79 , ổn định TB
- NB: Ổn định, acc trung bình
- CART: Median 0.7584, biến thiên cao

Tuning & Kết Quả Final – MinMaxScaler

Mô hình	CV Acc	Train Acc	Gap
KNN	0.8114	0.8496	3.82%
SVM	0.8249	0.8305	0.56%

- KNN: $n=7$
- SVM: $C=1$, $\gamma=\text{auto}$
- SVM > KNN +1.35%, ổn định hơn
- Gap nhỏ $\rightarrow$ ít overfit
- **Chọn SVM, KNN làm final**
- StandardScaler > MinMax

Kết Quả Test – MinMaxScaler

Mô hình	Not Survived	Survived
SVM	225	193
KNN (Backup)	218	200

- **SVM** dự đoán cân bằng, ổn định.
- **KNN** thiên nhẹ về lớp sống sót.
- Cả hai có phân bố gần tương đương.
- Chốt: **SVM + MinMaxScaler** hiệu quả hơn.

So Sánh 2 Phương Pháp Chuẩn Hóa

Tiêu chí	StandardScaler (Model 1)	MinMaxScaler (Model 2)
Data	df_standard.xlsx	df_minmax.xlsx
Baseline Best	SVM: 0.8238 ± 0.0175	SVM: 0.8317 ± 0.0117
Baseline Median	SVM: 0.8156	SVM: 0.8258
Mô hình Tuning	LR + SVM	KNN + SVM
Tuning Best (CV)	SVM: 0.8283	SVM: 0.8249
Tuning Train Acc	0.8339	0.8305
Gap (Overfitting)	0.56%	0.56%
Kết luận	Ổn định tốt	Ổn định tốt

- **MinMaxScaler:** Hiệu suất baseline cao hơn, ổn định khi chưa tuning.
- **StandardScaler:** Cải thiện hiệu quả hơn sau khi tuning (SVM đạt 82.83%).
- Cả hai phương pháp đều ổn định và cho kết quả gần tương đương.

Kết Luận

- Model 1: SVM + StandardScaler Kaggle: 0.72248
- Model 2: SVM + MinMaxScaler Kaggle: 0.71770
- Cả hai ổn định, gap $< 1\%$
- Nộp chính: Model 1 (GridSearchCV)
- Nộp phụ: Model 2 (RandomizedSearchCV)
- Hướng tới: XGBoost + Cabin + Age GAN

Cảm ơn thầy và các bạn!